版本感知与证据约束的 科研 Agent

第二阶段技术报告研发稿

真实运行证据、模型待验收与未完成事项分别记录。



参赛者 / 学校 / 组别：待选手填写。 AI辅助研发，未虚构人工标注或真实模型效果。

版本：2026-10-16T16:58:00+08:00。依据本地官方规则存档，供选手理解、复现和继续完善；不是已完成全部六模块的最终参赛声明。

1. 概述与实际问题

科研助手常把不同修订版本混为一个来源，给真实引文配上不受支持的结论，或在工具失败后仍输出似是而非的答案。研证以Version-Aware Evidence-Grounded Research Agent为工程假设：文献身份、版本、页块证据、工具状态与断言支持状态必须能逐项检查。

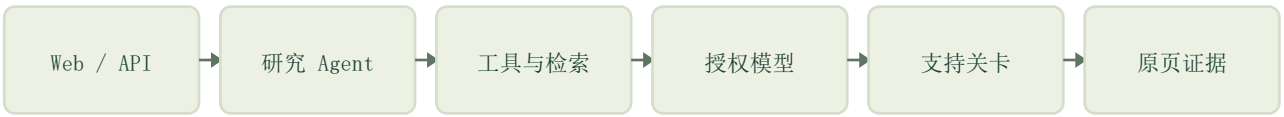
沿用第一阶段FastAPI/SQLite/PyMuPDF/OCR、BM25+字符RRF、家族PageRank与arXiv追踪，不重新选题、不训练新基础模型。LLM适合意图理解、多步工具选择、改写综合和翻译；版本过滤、引用定位、数值线索与预算由确定性模块处理。当前无授权模型，所以本轮没有真实LLM效果结论。

2. 官方需求与范围

官方要求基于LLM+Agent的科研助手，涵盖PDF解析、RAG、联动翻译、搜索追踪、图谱综述、写作可视化。Agent与模型深度35%、科研创新25%，其余四项各10%；详细出处见docs/competition_requirements.md及原始接口存档。可用第三方API，不强制本地；禁止把Mock或合成样例冒称真实推理/官方测试。

提交要求包括真实Git历史、可复现源码/README/配置、5-8分钟1080p普通话MP4、30页以内技术PDF和公网演示。现在没有公网、正式视频、官方扫描包全量验收或真实模型结果，不能宣称提交完备。参赛个人信息与许可仍需选手核对。

3. 架构与数据流



只读白名单 / 同源恢复 / 共享累计预算 / 模式明确区分

Web → app.py → ResearchAgent → 来源版本策略 → 白名单工具 → 模型消息历史 → 引用完整性 → 独立保守支持关卡 → 原文锚点。model.py负责OpenAI兼容消息/显式探测；model_budget.py跨客户端/进程累计预留；run_state.py持久状态/租约；translation.py处理段落对齐与保护标记；research_map.py提供启发式主题与来源日期。

底层retrieval.py继续冻结，新增策略通过独立模块复用检索结果，不把词汇方法叫Dense。原21份演示PDF不改；另有FNO v1/v3和MoleculeNet v3的独立评测缓存，原始作者页/版本/文件哈希存档。系统架构与算法Mermaid见docs/system_architecture.md及docs/phase2_evidence_flow.md。

4. 结果驱动、有界且可恢复的Agent

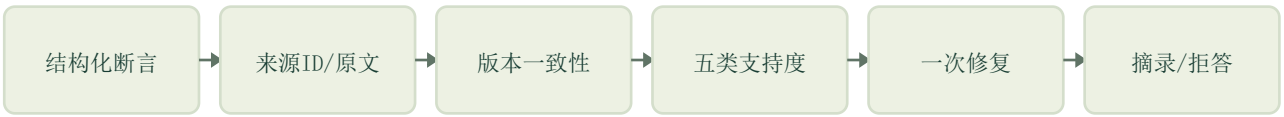
显式请求真实模型后，模型看到用户目标、规则意图提示和当前版本策略，可调用search_library、retrieve、versions、graph、future_work、outline。arXiv元数据工具默认不可用，只有用户勾选允许向arXiv发送本问题主题词才开放，且不允许发送文档中新增词汇。元数据不是全文证据，自动下载/导入不在模型白名单内。

工具参数使用严格Pydantic类型、extra=forbid，paper_ids只能来自当前选定且未被版本策略排除的文献。结果通过原生tool消息返回，模型可修正失败参数或继续检索；最多4模型回合/6工具。非法标识、重复调用ID、格式截断与上下文超限均明确处理。未支持断言最多一次修复；无效循环达到上限后仅返回允许的原文摘录或拒答。

端点拒绝工具请求时可退为确定性检索+一次真实JSON回答，标记real_llm_rag_compatibility；这不是原生规划。模型不可用则extractive_fallback，不把抽取模式当真实Agent。初版两次固定请求已由新循环替代，旧确定性兼容入口保留。

每个模型响应、工具调用及完成ID写本地状态。崩溃租约过期后，同目标/同源指纹/同版本及联网权限才能恢复；完成记录读取缓存不追加费用。工具尝试在执行前记数，模型尝试先作预算预留；崩溃/超时不自动返还，以避免隐性重复消费。读工具在执行与状态落盘之间崩溃仍可能重读，不宣称分布式恰好一次。

5. 证据支持与版本创新



只读白名单 / 同源恢复 / 共享累计预算 / 模式明确区分

原有quote+chunk_id校验仍作为低层完整性条件。新增独立关卡区分fully_supported、partially_supported、evidence_conflict、insufficient_evidence、cannot_judge。只自动放行完整来源摘录；不完整PDF行、未知改写和不匹配版本拒收。数值不一致、同家族不同版本单位值差异只作为冲突候选，可能是实验配置不同，需要科研人员复核。

这不是通用语义蕴含，也不证明现实事实。只有“文献这样表述”的窄支持范围；模型自评分不作为真值。保守策略有明显覆盖损失，真实多篇综合改写质量仍待授权模型/外部人工验证。未经校验的断言不会因引文真实而自动发布。

版本策略latest/all/explicit基于本次文献集合，不声称已知全网最新。较旧来源提示与精确版本URL随证据保存；用户明确旧版时应尊重。原文diff继续可用；字词段落对齐只提取GPU/TPU/层数/批次等数值变化候选，不把排版变化当结论改变。当前两组真实修订版均未找到该规则覆盖的数值变化，不能展示虚构“新旧结论冲突”。

6. 实验设计、结果与代价

第一阶段开发/新论文检索指标保留为历史检索对照：开发调优后全目标命中100%，两篇新论文11/12；不当作回答准确率。第二阶段完整回归130通过，失败0、错误0、跳过0；1条上游AnyIO弃用警告。XML来源experiments/full_tests_20261016_165150.xml。

本轮真实运行的离线策略实验：10条错误合成断言绑定真实来源，旧完整性校验放行10，保守关卡发布0；6条原文摘录仅5通过。它们是来源约束策略探针，不是模型幻觉率、回答正确率或无偏NLI准确率。误拒/片段风险保留，不只报告收益。原始payload/evidence/audit见experiments/phase2_offline_20261016_165330。

18任务草案含6开发与12冻结新应用任务，均AI辅助来源核对，无外部人工金标。新PDF曾用于工程解析检查，不称作整个系统完全未见数据。无真实模型输出可供调Prompt；未来必须只在开发集调优，若观察冻结集失败后修改则另建最终集。数据SHA锁与检索SHA随运行配置保存。

四基线direct_llm/conventional_rag/citation_integrity_rag/proposed_agent，以及去版本、去关卡、去事实重排、去模型规划四消融，已实际完成96条计划检查，真实模型完成0。质量/Token/费用值均null。相同模型/任务/温度/每次输出限额，但Agent计算量可能更多，不能称等成本。指标分母、Wilson区间、部分/未知支持的处理详见docs/phase2_evaluation_protocol.md。

7. 阅读、翻译、图谱与科研发现

按页真实版式图与原文bbox定位、数字引用往返保留。新增翻译段落ID/bbox对齐、术语表与所识别公式/数字/Greek符号/引文保护；缺失/重复标记、缺段落会拒收。切页后旧翻译响应不覆盖新页。真实模型未配置返回503，完整性替身测试不等于翻译正确性。

图谱沿用20家族71边与来源锚点/聚焦/SVG。新增标题TF-IDF启发式聚类14簇、公开首发日期19条与未知1条；没有人工主题质量分。380有向配对标注表全部为空，算法候选不是人工真值。Future Work只列来源候选，归属/后续解决状态未确认；证据归纳机会与模型假设分开，当前两者为空，不能凭猜想宣布已证明方向。

8. 工程、预算与复现

依赖保持现有固定版本，配置来自RESEARCHTRACE环境变量，密钥不进源码、SQLite或Web。模型默认禁用；当前.env缺失，两个本机模型服务不可达。默认最多8累计请求、100000保守预留单位、每请求1600输出Token，失败/重试计入共享账本。美元上限需要用户提供两种单价；缺失实际usage/单价时费用null，不把估算当账单保证。

按README使用Python3.12与requirements-dev.txt启动127.0.0.1:8000，运行scripts/run_tests.py、phase2_offline_experiments.py、evaluate_phase2_qa.py默认计划、phase2_live_probe.py。模型授权后按docs/phase2_model_acceptance.md小批验收，再显式--execute-models；预算不足明确停止，不自动提额。恢复ZIP排除密钥、原PDF、数据库、权重和venv，来源锁与实际实验仍保留。

9. 真实边界、AI协作与下一步

本轮由AI辅助审计、实现、构造来源任务与测试；没有外部人工标注、真实LLM推理或翻译实验，没有远程推送/付费调用/购买/公网部署。选手应亲自理解和复现核心算法，不能把自动生成材料当人工研究贡献。创新是可检验的应用工程组合，未证明基础算法原创或性能优势。

优先补授权模型与足够预算，真实运行四基线/四消融及双人抽查；补官方扫描包和复杂段落/表格/公式、真实翻译及通用语义支持验证；最后完善访问控制/评审仓库/普通话MP4。内部成熟度不替代官方评分，也不宣称一等奖水平。