版本感知、证据约束的科研助手

传智杯 AI 大模型创新应用挑战赛
技术报告 • 研发原型与真实实验

报告状态：可运行研发稿，尚未达到完整竞赛提交状态。
没有真实大模型推理结果，不宣称一等奖水平。



已完成：PDF/OCR、版本检查、证据检索、20家族图谱、CSV与本地工作台。
主要缺项：真实LLM、复杂公式表格、专业翻译联动、长期追踪与公网部署。

参赛者、学校、组别、指导教师：待用户填写。
AI协同研发，真实阶段记录与复现命令随项目提供。

证据生成时间：2026-10-16T07:44:00+08:00

01 / 命题、需求与场景

官方要求一款融合大语言模型与Agent架构的全流程科研助手，全面覆盖六模块：PDF细粒度解析、抗幻觉问答、联动翻译阅读、检索追踪推荐、引用图谱与综述、写作可视化。官方允许第三方API和AI辅助编程，不强制本地模型。

维度	权重	本项目关注
Agent与大模型深度	35%	证据检索、受限规划、原生工具协议、引用核验、OCR
科研场景创新	25%	版本家族、跨篇配额、细粒度硬件事实定位
工程、实用、UI、学术价值	各10%	可运行、可追溯、可恢复及真实验证

真实问题

研究者要比对论文训练设备和超参数时，搜索结果常混入摘要、修订版本和邻近主题；通用生成又可能把记忆当作正文证据。研证把论文版本、页/块坐标、检索结果与引用校验关联起来，让用户回到原文核验。

大模型的必要性与边界

LLM适合自然语言意图拆解、跨文综合、翻译与写作；数字统计、引用字符串校验和图算法由确定性程序负责。缺少已授权模型时，系统仅显示抽取证据和模板，不把它们包装为LLM回答。

选择依据

同一官方命题下比较了通用论文聊天、全自动科研假设代理、版本证据助手三个侧重方向。选择第三种，是因为它的差异可以通过版本误认、证据覆盖和引用伪造实验核验；没有宣称基础算法首创。

提交与合规

官方要求源码托管及真实Git历史、环境说明、5-8分钟1080p普通话MP4、最多30页PDF、公网演示。当前只有本地Git，未推送、未发布、未购买云资源。页面中部分日期/奖项比例存在内部矛盾，已在规则文档列待确认。

02 / 系统架构与工程实现

Web工作台 → FastAPI → 文档导入/有界工作流 → SQLite与原始PDF → 检索/图谱/CSV工具 → 证据输出或可选模型 → 引用校验 → 页图定位。

模块	真实职责
parsing.py	逐页提取文本/bbox/标题/参考文献；无文本时英语OCR；首页识别arXiv身份。
store.py	SQLite存储文献、块与反馈；删除索引保留原PDF。
retrieval.py	BM25、字符三元组、RRF、文献配额与设备事实重排；引用原文子串验证。
model.py / planner.py	默认关闭的真实接口适配；原生工具调用白名单，最多4步；超时和有限重试。
agent.py / tools.py	确定性流程轨迹、部分拒答、家族PageRank、Future Work、arXiv、CSV与写作模板。
app.py / web	API、上传、原文下载、服务端页图与证据框、联动正文/译文工作台。

可靠性与资源控制

单文件默认32MiB、最多1200页、问题最多6000字符；模型45秒超时与最多2次尝试；不接受任意URL下载或执行生成代码。密钥只来自环境。默认仅监听127.0.0.1。

文档保真策略

原PDF保留，页图只是交互渲染结果。证据块含物理页码和bbox，定位时可绘制高亮框。发现内置浏览器PDF插件黑屏后改为页图预览；这不等于PDF.js原生文字选择，也不等于公式/表格语义还原。

03 / 算法设计与创新边界

设计	机制	不可夸大的边界
版本感知	正文4-shingle Jaccard与首页arXiv标识；版本确认与差异比较	词汇近似并非学习式语义；不能仅一对版本报告去重准确率
跨文检索	BM25与字符RRF；每篇至少一个候选；设备数字信息重排	没有神经Dense模型；配额可能损害全局相关性
证据约束	块ID存在性、原文quote子串、输出结构与部分拒答	真引用仍可能支撑假结论，尚未验证语义蕴含
版本家族图谱	同论文多版合并代表节点，标题/标识匹配引用并计算PageRank	边只指论文家族，不能当作引用了最新修订版
Future Work线索	原文候选提取与词汇去重	不自动断言问题仍未解决或想法具有原创性

LLM规划状态

已实现原生Function Calling、白名单工具执行和tool消息返回综合，但无已授权端点，实际运行仍是明确披露的确定性流程。原生协议仅通过Mock传输测试。模型MockTransport只测试网络契约，不产生科研效果数据。

为何比普通API包装更可审查

系统有可重算算法、真实PDF版本来源、逐页证据与坐标、错误引用拒绝探针、独立保存的基线/消融、旧版防静默覆盖和可恢复日志。它仍是研发原型，不能因这些工程机制就宣称已完成科研自主推理。

04 / 检索实验与消融

固定k=5。严格全目标命中要求选中指定论文、页码和原文子串；目标召回按标签计。该指标不是回答准确率；其他等价证据可能未被标签覆盖。开发集用于调参，另用两篇新论文验证，不混为盲测。

开发集：18个有答案问题

方案	全目标@5	目标召回@5	跨篇全命中	中位ms
bm25	66.7%	71.4%	0.0%	14.34
char	72.2%	71.4%	0.0%	14.36
融合无配额	77.8%	81.0%	0.0%	15.02
融合有配额	83.3%	85.7%	33.3%	13.96
完整方案	100.0%	100.0%	100.0%	13.75

新论文验证：12个有答案问题

方案	全目标@5	目标召回@5	跨篇全命中	中位ms
bm25	75.0%	78.6%	100.0%	48.35
char	66.7%	71.4%	50.0%	48.77
融合无配额	91.7%	92.9%	50.0%	51.10
融合有配额	91.7%	92.9%	50.0%	49.82
完整方案	91.7%	92.9%	50.0%	54.36

开发集完整方案100%是适配后结果。新论文完整方案11/12；cross_new_batch未完整命中。配额与设备事实重排在新论文上没有增加总体命中；BM25在两道跨篇题均命中，而融合完整方案只命中一道。不能声称所有模块均有泛化收益。

开发集跨篇仅3题，新论文跨篇仅2题；没有显著性结论、真实用户效率或官方通过率。未进行LLM回答基线/消融，Token与费用记为未测，而不是0成本性能证明。

05 / OCR、长文与鲁棒性

文档	页/块	用时秒	Python峰值MiB
合成541页压力样例	541/541	0.542	2.73
合成扫描样例	1/2	0.151	18.24
真实同名作者版教材	541/7190	7.736	34.82

真实教材从作者官网链接的v5.0.3发布下载，文件名与赛题相同，541页、7190块，其中4页真实OCR。但未对照官方资料包哈希。峰值只计Python tracemalloc，不包括原生PDF/OCR内存，不能当作系统总内存。

真实论文派生扫描（原第1和7页）

原页	去重词召回	去重词精确率
1	93.12%	93.12%
7	95.76%	96.58%

该扫描由真实PDF栅格化产生，不是官方img.pdf。去重词指标不是字符准确率、WER或公式/版式识别准确率；扫描OCR可以运行，不等于复杂学术PDF全面通过。

自动化与失效探针

最新自动化：89项，失败0，错误0，跳过0。覆盖无效PDF、随机改名版本、来源锚点、图谱版本、私密/年份拒答、非法参数、CSV边界、超时与JSON契约。初始失败日志仍保留。

真引用假结论探针仍通过：这是已确认的语义漏洞。新论文3个无答案探针在应用层均拒答，但不能推导一般未知问题拒答率。英语OCR路径需相对英文目录；中文语言数据与复杂表格公式尚未验收。

06 / 六模块验收与严格内部评审

官方模块	当前证据	主要缺项
PDF解析	真实版本与541页/OCR	表格结构、公式LaTeX、机构元数据
RAG多文问答	真实检索与引用锚点	真实LLM、Dense、语义蕴含
联动阅读翻译	页图与正文译文滚动机制	真实翻译、划词、非数字引文无损跳转
追踪推荐	真实arXiv、下载API和本地兴趣排序	长周期稳定性、训练式推荐、多用户
引用图谱与前沿	家族PageRank与原文候选	大规模标注、LLM综述、后续解决验证
写作可视化	模板、真实条目、CSV和Mermaid	真实生成质量、多图形/全文翻译

内部成熟度43/100（非官方评分、非获奖预测）

Agent深度11/35、创新10/25、工程7/10、实用5/10、UI6/10、学术价值4/10。没有真实模型效果与完整六模块的证据，不给完成度或模型效果虚高分。

已经修复的高优先问题：PDF插件黑屏、v7标题误提取、教材身份被参考文献污染、版本重复计权、随机字符弱相关、私密信息与不存在年份拒答。

下一步前三项：1）由用户配置并授权模型与调用预算，执行真实规划/综合/翻译和安全实验；2）取得官方资料包，完善公式表格与翻译阅读，再进行更广盲测；3）经人工理解复现后准备受保护公网服务、评审仓库与正式视频。

07 / 按页结构与有界追踪

表格提取：从整页误检到表题约束

整页文字策略把Attention的表格与正文合成64行8列。新流程先定位表题与邻近短行；同一水平带存在并列表题时再隔离文字列；最后按坐标恢复行列，保留原始文字及bbox。按页惰性计算和版本化缓存，避免导入541页时逐页检测表格。

阶段	列数匹配案例	指定单元格	保留的反例
v2表题限定	6/8	15/18	RAG并排双表合并
v3横向隔离	8/8	18/18	合成短表题宽表丢列
v4邻表条件隔离	8/8	18/18	宽表回归已修复，仍未证明全部单元格正确

这些页面已参与开发/修复，不是独立盲测。关键单元格指标不覆盖合并表头、指数、缺值、扫描表格。图注、嵌入图片和数学字体glyph分别呈现，未声称图文配对或LaTeX转录完成。CSV明确为未核验导出，潜在公式文本做中和处理。

真实目录与结构交互

教材181条原生书签形成目录层级；精确标题匹配失败时只保留页定位。界面支持任意页跳转、结构表格、CSV下载与原页表格框；真实HTTP记录缓存标记和输出，不把缓存命中当作首次解析耗时。

有界文献追踪

默认空列表，创建默认停用；只有用户启用才按30-1440分钟间隔访问公共arXiv元数据。每条最多48次，每调度周期最多2条；事务租约防并发重入，版本去重和错误历史持久化。没有LLM或外部消息。

真实受限实验为30分钟间隔、最多2次：01:55:39与02:26:07两份快照成功，第二条记录scheduled；达到上限后enabled=0、disabled_reason=refresh_limit_reached已实际观察。第一条早于触发类型字段，保留unspecified，不补写。不能将两次观察推广为长期稳定性。

08 / 引用图来源与证据核验

从参考文献出发的受限扩展

原始7份文献基础上，依据真实参考条目里的arXiv标识下载14篇，共12,681,905字节；总计21份PDF、20个论文家族。每次限制数量、单文件大小和下载间隔，保留来源与SHA256，不重新分发原PDF。20个arXiv版本经一次公共Atom批次精确ID与版本匹配，补充作者、完整标题和首发年；机构缺失保持空，教材年份未知。

相同输入的匹配前后对照

项目	真实观察	解释边界
引用边	64 → 71	相同已校验元数据与文献ID
锚点完整性	71/71	块存在、物理页及原参考文本一致
新增边原文核对	7/7	改动后修复回归，非独立金标
PageRank残差	7.8e-11	非加权家族图；不代表质量

新匹配逐条处理参考文献，归一化断行、连字和小型大写；完整标题终止边界防止短书名误匹配长论文名。不同参考条目不能拼接成命中。旧算法64边基线在元数据更新后保存；另一份更新前基线有混杂因素，未用来声称算法提升。

核验与展示

7条新增引用核对原PDF对应物理页的文本块、作者与完整标题。最初整页排序会交错双栏导致5条核验失败，按块保持阅读顺序后7条通过，旧输出保留。此为来源核对，不证明语义蕴含、全图精确率或引用质量。界面采用编号图例、论文聚焦、逐边原文跳转和SVG导出，避免20节点标题重叠。

正文数字引文频次只统计参考文献首页之前的块，作者年份、范围引用和同页引文可能漏计；边只表示论文家族关系，不推断引用最新版本。仍缺独立全图标注、应付式引用过滤、真实LLM综述、Future Work后续解决验证。

09 / 复现、来源与提交状态

最小复现

Python 3.12创建venv并安装requirements-dev.txt；下载公开论文、作者版教材及英语OCR数据；scripts/import_papers.py导入；uvicorn src.app:app --host 127.0.0.1 --port 8000启动。逐条命令见README。

pytest；scripts/evaluate.py；scripts/evaluate.py data/holdout_cases.json；scripts/robustness.py；scripts/scan_real_sample.py；启动服务后scripts/live_smoke.py。每轮保留时间戳原始证据、配置、数据哈希与汇总。

实验来源目录

development: experiments\retrieval_20261016_005801

holdout: experiments\retrieval_20261016_010526

test_xml: experiments\full_tests_20261016_074255.xml

robustness: experiments\robustness_20261016_020249.json

real_scan: experiments\real_scan_20261016_010636.json

离线恢复：锁定21份原PDF，隔离临时SQLite重新解析、恢复20份Atom元数据，20节点/71边的源页/块与排名完全一致（6.69秒、零联网、原库未修改）。不是新机器安装或公网重下载验收。精确命令见README，来源：experiments\rebuild_20261016_074205

公开原始来源

官方赛道：https://www.boxuegu.com/matchTrack/detail/?id=10040
规则原始接口与正文：docs/sources/official_track_raw.json、official_rules.txt。
真实论文：arxiv.org 的 1706.03762v1/v7、1810.04805v2、2005.11401v4、2005.14165v4、2004.04906v2。
教材作者：https://udlbook.github.io/udlbook/，v5.0.3同名教材。
OCR数据：github.com/tesseract-ocr/tessdata_fast，来源与哈希随附。

提交与原创性声明

AI协同说明与Prompt位于docs/ai_collaboration.md及源代码。原PDF不随Git分发，依赖/模型/文献许可按上游核验，项目源码公开许可待用户决定。Dockerfile已写但未运行验收；公网、正式MP4、评审仓库权限、团队信息、官方完整测试尚未完成。

所有结论仅基于列明的真实运行证据。没有调用付费模型，没有擅自推送、提交比赛、购买资源或虚构测试。